

Análisis de Series Temporales

Clase 3 - Modelos de Medias Móviles

Rodrigo Del Rosso
RDelRosso-ext@austral.edu.ar

16 de Octubre de 2021



CIENCIA DE DATOS

Maestría en **Ciencia de Datos**

Agenda

- Relación entre procesos $AR(1)$ y $MA(\infty)$
- Representación de procesos $MA(1)$
- Representación de procesos $MA(2)$
- Estacionariedad e Invertibilidad
- Comparación de procesos $MA(q)$ con $AR(p)$



MODELO DE MEDIAS MÓVILES (MA)

Modelo de Medias Móviles (MA)

Un modelo de medias móviles de orden q , o abreviadamente un modelo $MA(q)$, se define de la siguiente forma:

$$Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \dots - \theta_q \varepsilon_{t-q}$$

Conviene señalar que los coeficientes van precedidos por el signo negativo, por cuestión meramente de conveniencia en la notación.

Utilizando el operador polinomial de retardos: $\theta(L) = 1 - \theta_1 L - \theta_2 L^2 - \dots - \theta_q L^q$

El modelo de medias móviles se puede expresar de forma compacta:

$$Y_t = \theta(L) \varepsilon_t$$

La **media** de un modelo MA es **cero**, cualesquiera que sean los valores de θ :

$$E[Y_t] = \theta(L) E[\varepsilon_t]$$

Modelo de Medias Móviles (MA)

Si, en cambio, en el modelo original se incluye el término constante:

$$Y_t = \delta + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \dots - \theta_q \varepsilon_{t-q}$$

Entonces, al tomar esperanzas matemáticas en la expresión anterior resulta:

$$E[Y_t] = \underbrace{\delta + \theta(L)}_{=0} \underbrace{E[\varepsilon_t]}_{\delta}$$

Así pues, en los modelos de medias móviles, la media del proceso coincide con el término independiente. Sin pérdida de generalidad, **en adelante supondremos que $\delta = 0$.**

Auto-test

¿Se entiende la idea de estos modelos? ¿Qué significado le dan a los rezagos del error? ¿Qué dice el libro de Peña al respecto?

Modelo de Medias Móviles (MA)

ESTACIONARIEDAD

Los modelos MA son **SIEMPRE estacionarios** con independencia de los valores de los coeficientes, ya que son combinaciones lineales de errores ruido blanco.

INVERTIBILIDAD

Dado que los modelo MA son estacionarios, pueden ser invertible en un $AR(\infty)$ bajo ciertas condiciones. La invertibilidad se puede evaluar ya sea a partir de las raíces de la Ecuación Característica (EC) como a partir de las raíces del Polinomio Característico (PC).

$$|Raices\ EC| < 1$$

$$|Raices\ PC| > 1$$

A diferencia de los modelos AR, los modelos de Medias Móviles tiene **memoria finita**. Recordemos a continuación un concepto de los $AR(1)$...

Recordemos: MODELOS AUTORREGRESIVOS DE PRIMER ORDEN – $AR(1)$

- Recuerden que por raíces:
 $|Raíces\ EC| = |Raíces\ PC|^{-1} \rightarrow \text{Criterios Ec. o Polinom. Caract.}$
- INVERTIBILIDAD: (*Propiedad*) “Todo proceso autorregresivo estacionario es invertible en un modelo $MA(\infty)$, que siempre es estacionario”.

Esta propiedad indica que:

- Todo proceso autorregresivo estacionario admite ser expresado alternativamente mediante un modelo de promedios móviles de orden infinito.
- La condición, es que el modelo AR sea estacionario

Los procesos MA son siempre estacionarios. Hay dos formas para obtener la expresión $MA(\infty)$ a partir de un proceso $AR(1)$:

- (i) Aplicando el método de “reemplazos sucesivos”
- (ii) Trabajando con el “polinomio operador de retardos”

Relación entre $AR(1)$ y $MA(\infty)$

i Método de “reemplazos sucesivos”:

Partimos de la expresión del proceso: $Y_t = \phi Y_{t-1} + \varepsilon_t$ Al conocer la forma del proceso, sabemos que: $Y_{t-1} = \phi Y_{t-2} + \varepsilon_{t-1}$, reemplazo:

$$Y_t = \phi(\phi Y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t \implies Y_t = \phi^2 Y_{t-2} + \phi \varepsilon_{t-1} + \varepsilon_t$$

Nuevamente: $Y_{t-2} = \phi Y_{t-3} + \varepsilon_{t-2}$, entonces:

$$Y_t = \phi^2(\phi Y_{t-3} + \varepsilon_{t-2}) + \phi \varepsilon_{t-1} + \varepsilon_t \implies Y_t = \phi^3 Y_{t-3} + \phi^2 \varepsilon_{t-2} + \phi \varepsilon_{t-1} + \varepsilon_t$$

Relación entre $AR(1)$ y $MA(\infty)$

(i) Método de “reemplazos sucesivos”: (*continuación...*)

Si continuamos realizando reemplazos, es posible inferir que se alcanza una expresión del tipo:

$$Y_t = \phi^N Y_{t-N} + \underbrace{\phi^{N-1}\varepsilon_{t-(N-1)} + \phi^{N-2}\varepsilon_{t-(N-2)} + \dots + \phi\varepsilon_{t-1} + \varepsilon_t}_{MA(N-1)}$$

Según propiedades del límite, se tiene:

$$\begin{aligned} \lim_{N \rightarrow \infty} Y_t &= \underbrace{\lim_{N \rightarrow \infty} (\phi^N Y_{t-N})}_{\rightarrow 0} + \\ &\quad + \underbrace{\lim_{N \rightarrow \infty} \left\{ \phi^{N-1}\varepsilon_{t-(N-1)} + \phi^{N-2}\varepsilon_{t-(N-2)} + \dots + \phi\varepsilon_{t-1} + \varepsilon_t \right\}}_{\rightarrow MA(\infty)} \end{aligned}$$

$$\therefore \lim_{N \rightarrow \infty} Y_t = MA(\infty)$$

En definitiva, estamos en condiciones de afirmar que, cuando la cantidad de “reemplazos” realizados crece indefinidamente, se obtiene la expresión del modelo $AR(1)$ estacionario original como un modelo $MA(\infty)$.

Relación entre $AR(1)$ y $MA(\infty)$

(ii) Trabajando con el polinomio operador en retardos, $\Psi(L)$:

Partimos de la expresión del proceso:

$$Y_t = \phi Y_{t-1} + \varepsilon_t \implies Y_t - \phi Y_{t-1} = \varepsilon_t$$

Expresamos todo a partir del operador retardo (L):

$$(1 - \phi L) Y_t = \varepsilon_t \implies Y_t = \frac{1}{1 - \phi L} \varepsilon_t$$


Dado que el polinomio operador de retardos se define de la siguiente manera:

$$\frac{1}{1 - \phi L} = \Psi(L) = \left(1 + \Psi_1 L + \Psi_2 L^2 + \Psi_3 L^3 + \dots\right)$$

Entonces: $Y_t = \Psi(L) \varepsilon_t = \left(1 + \Psi_1 L + \Psi_2 L^2 + \Psi_3 L^3 + \dots\right) \varepsilon_t$

Distribuyendo se tiene:

$$Y_t = \varepsilon_t + \Psi_1 \varepsilon_{t-1} + \Psi_2 \varepsilon_{t-2} + \Psi_3 \varepsilon_{t-3} + \dots \rightarrow MA(\infty)$$



Importante

Obtuvimos la expresión del modelo $MA(\infty)$, nos resta obtener la expresión de los coeficientes Ψ_i , en función del coeficiente del modelo original, ϕ .

Relación entre $AR(1)$ y $MA(\infty)$

(ii) Trabajando con el polinomio operador en retardos, $\Psi(L)$ (*continuación...*):

Sea

$$\frac{1}{1-\phi L} = \left(1 + \psi_1 L + \psi_2 L^2 + \psi_3 L^3 + \dots\right)$$

Entonces: $1 = (1 - \phi L) \left(1 + \psi_1 L + \psi_2 L^2 + \psi_3 L^3 + \dots\right)$

Distribuyendo:

$$1 = 1 - \phi L + \psi_1 L - \phi \psi_1 L^2 + \psi_2 L^2 - \phi \psi_2 L^3 + \psi_3 L^3 + \dots$$

Agrupando:

$$1 = 1 + (\psi_1 - \phi)L + (\psi_2 - \phi\psi_1)L^2 + (\psi_3 - \phi\psi_2)L^3 + \dots$$

Relación entre $AR(1)$ y $MA(\infty)$

(ii) Trabajando con el polinomio operador en retardos, $\Psi(L)$ (*continuación...*):

$$1 = 1 + (\Psi_1 - \phi)L + (\Psi_2 - \phi\Psi_1)L^2 + (\Psi_3 - \phi\Psi_2)L^3 + \dots$$

Igualando miembro a miembro cada término de los polinomios obtenidos:

$$1 = 1$$

$$0.L = (\Psi_1 - \phi)L \implies \Psi_1 - \phi = 0 \implies \boxed{\Psi_1 = \phi}$$

$$0.L^2 = (\Psi_2 - \phi\Psi_1)L^2 \implies \Psi_2 - \phi\Psi_1 = 0 \implies \Psi_2 = \phi\Psi_1 \implies \boxed{\Psi_2 = \phi^2}$$

$$0.L^3 = (\Psi_3 - \phi\Psi_2)L^3 \implies \Psi_3 - \phi\Psi_2 = 0 \implies \Psi_3 = \phi\Psi_2 \implies \boxed{\Psi_3 = \phi^3}$$

...

Importante



De este modo obtuvimos la expresión de los coeficientes del modelo $MA(\infty)$ en función del coeficiente del

$AR(1)$ dado: $\boxed{Y_t = \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \phi^3 \varepsilon_{t-3} + \dots}$

Procesos $MA(1)$

Ahora que ya vimos algunas cosas,
vamos en detalle con Medias Móviles. . .



Procesos $MA(1)$

$$MA(1): Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} \quad \varepsilon_{t-1} = (1 - \theta_1 L) \varepsilon_t$$

Si se multiplican ambos miembros de la ecuación anterior por Y_{t-k} y se toman esperanzas matemáticas se tiene que:

$$Y_t \cdot Y_{t-k} = (\varepsilon_t - \theta_1 \varepsilon_{t-1}) \underbrace{Y_{t-k}}_{(\varepsilon_{t-k} - \theta_1 \varepsilon_{t-k-1})}$$

$$E[Y_t \cdot Y_{t-k}] = E[(\varepsilon_t - \theta_1 \varepsilon_{t-1})(\varepsilon_{t-k} - \theta_1 \varepsilon_{t-k-1})]$$

Puede verse que para $k = 0$, resulta:

$$E[Y_t^2] = E[(\varepsilon_t - \theta_1 \varepsilon_{t-1})^2] = E[\varepsilon_t^2 + \theta_1^2 \varepsilon_{t-1}^2 - 2 \theta_1 \varepsilon_t \varepsilon_{t-1}] =$$

$$= \underbrace{E[\varepsilon_t^2]}_{\sigma_\varepsilon^2} + \theta_1^2 \underbrace{E[\varepsilon_{t-1}^2]}_{\sigma_\varepsilon^2} - 2\theta_1 \underbrace{E[\varepsilon_t \varepsilon_{t-1}]}_{=0} = \boxed{(1 + \theta_1^2)\sigma_\varepsilon^2 = \gamma_0}$$

Procesos $MA(1)$

$$MA(1): Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} = (1 - \theta_1 L) \varepsilon_t$$

$$\text{Tenemos entonces: } E[Y_t \cdot Y_{t-k}] = E[(\varepsilon_t - \theta_1 \varepsilon_{t-1})(\varepsilon_{t-k} - \theta_1 \varepsilon_{t-k-1})]$$

Puede verse que para $k = 1$, resulta:

auto covarianza

$$E[Y_t \cdot Y_{t-1}] = E[(\varepsilon_t - \theta_1 \varepsilon_{t-1})(\varepsilon_{t-1} - \theta_1 \varepsilon_{t-2})] =$$

$$= \underbrace{E(\varepsilon_t \varepsilon_{t-1})}_{=0} - \theta_1 \underbrace{E(\varepsilon_t \varepsilon_{t-2})}_{=0} - \theta_1 \underbrace{E(\varepsilon_{t-1}^2)}_{=\sigma_\varepsilon^2} - \theta_1^2 \underbrace{E(\varepsilon_{t-1} \varepsilon_{t-2})}_{=0} = \boxed{-\theta_1 \sigma_\varepsilon^2 = \gamma_1}$$

Para valor de $k > 1$, se deduce que: $\boxed{\gamma_k = 0}$

Auto-test

Entonces, ¿¡hemos deducido las funciones de autocovarianzas para un proceso $MA(1)$!! ¿Qué relación guardan con las de un $AR(p)$?

Procesos $MA(1)$

$$MA(1): Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} = (1 - \theta_1 L) \varepsilon_t$$

Para obtener las funciones de autocorrelación basta con reemplazar los valores de las autocovarianzas en la siguiente función:

$$\rho_k = \frac{\gamma_k}{\gamma_0}$$


Entonces,

$$\text{Para } k = 1 \implies \rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{-\theta_1 \sigma_\varepsilon^2}{(1+\theta_1^2) \sigma_\varepsilon^2} = \frac{-\theta_1}{(1+\theta_1^2)} = \rho_1$$

$$\text{Para } k > 1 \implies \rho_k = 0 \quad \forall k > 1$$

Procesos $MA(1)$

Una vez calculados los coeficientes de correlación correspondientes al proceso $MA(1)$ se pueden representar en un correlograma:

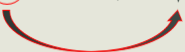


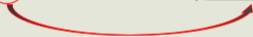
Procesos $MA(1)$

CONDICIONES DE INVERTIBILIDAD:

$$Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} \implies \varepsilon_t = Y_t + \theta_1 \varepsilon_{t-1}$$

Dado que los procesos $MA(1)$ son **SIEMPRE ESTACIONARIOS**, si efectuamos sustituciones sucesivas, resulta que:

$$\varepsilon_t = Y_t + \theta_1 \varepsilon_{t-1} = Y_t + \theta_1 \left(Y_{t-1} + \theta_1 \varepsilon_{t-2} \right) = Y_t + \theta_1 Y_{t-1} + \theta_1^2 \varepsilon_{t-2}$$


$$\varepsilon_t = Y_t + \theta_1 Y_{t-1} + \theta_1^2 \varepsilon_{t-2} = Y_t + \theta_1 Y_{t-1} + \theta_1^2 \left(Y_{t-2} + \theta_1 \varepsilon_{t-3} \right) = Y_t + \theta_1 Y_{t-1} + \theta_1^2 Y_{t-2} + \theta_1^3 \varepsilon_{t-3}$$


...

$$\varepsilon_t = Y_t + \theta_1 Y_{t-1} + \theta_1^2 Y_{t-2} + \dots + \theta_1^N Y_{t-N} + \theta_1^{N+1} \varepsilon_{t-(N+1)}$$



Se anidan las sustituciones
en este esquema recursivo
hasta llegar a esta expresión

Procesos $MA(1)$

CONDICIONES DE INVERTIBILIDAD: $Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1}$ (continuación...)

$$\varepsilon_t = Y_t + \theta_1 Y_{t-1} + \theta_1^2 Y_{t-2} + \dots + \theta_1^N Y_{t-N} + \theta_1^{N+1} \varepsilon_{t-(N+1)}$$

- Si $|\theta_1| < 1$, el último término de la expresión anterior tiene menos peso a medida que sea mayor N , y además el peso de cada Y_t retardada decrece a medida que crece el número de retardos. En consecuencia, si se cumple siempre esta condición, el modelo podrá expresarse así:

$$\varepsilon_t = Y_t + \theta_1 Y_{t-1} + \theta_1^2 Y_{t-2} + \dots$$

- De esta forma, se ha pasado de un $MA(1)$ a un $AR(\infty)$. La condición que permitió invertir un modelo en otro es: $|\theta_1| < 1$ y se denomina **"condición de invertibilidad"**.

CONDICIONES DE INVERTIBILIDAD: $Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1}$ (continuación...)

La condición de invertibilidad de un modelo $MA(1)$ es equivalente en sentido formal a la condición de estacionariedad de un modelo $AR(1)$. Cuando $|\theta_1| < 1$, entonces:

$$\varepsilon_t = \frac{1}{(1-\theta_1)L} Y_t$$

Puede verse como una ecuación en diferencias de ε_t :

$$Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} = \underbrace{(1 - \theta_1 L)}_{\text{Polin. Caract.}} \varepsilon_t$$

Para que esta ecuación sea estable se requiere que la raíz del polinomio característico $[1 - \theta_1 L = 0]$ caiga fuera del círculo unitario.

Es decir, $|L| = \left| \frac{1}{\theta_1} \right| > 1 \iff |\theta_1| < 1$

Procesos $MA(2)$

Amplíemos los rezagos. . . ¡veamos como convergen ciertas cosas al orden $q!$. . .



Procesos $MA(2)$

$$MA(2): Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} = (1 - \theta_1 L - \theta_2 L^2) \varepsilon_t$$

Si se multiplican ambos miembros de la ecuación anterior por Y_{t-k} y se toman esperanzas matemáticas se tiene que: $E[Y_t \cdot Y_{t-k}] =$

$$E \left[(\varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2}) \underbrace{(\varepsilon_{t-k} - \theta_1 \varepsilon_{t-k-1} - \theta_2 \varepsilon_{t-k-2})}_{Y_{t-k}} \right]$$

Puede verse que los distintos valores de k , resulta:

$$k = 0 \quad \longrightarrow \quad E[Y_t^2] = E[(\varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2})^2] =$$

$$E[\varepsilon_t^2 - 2\theta_1 \varepsilon_t \varepsilon_{t-1} - 2\theta_2 \varepsilon_t \varepsilon_{t-2} + \theta_1^2 \varepsilon_{t-1}^2 + 2\theta_1 \theta_2 \varepsilon_{t-1} \varepsilon_{t-2} + \theta_2^2 \varepsilon_{t-2}^2] =$$

$$= \underbrace{E[\varepsilon_t^2]}_{\sigma_\varepsilon^2} + \theta_1^2 \underbrace{E[\varepsilon_{t-1}^2]}_{\sigma_\varepsilon^2} + \theta_2^2 \underbrace{E[\varepsilon_{t-2}^2]}_{\sigma_\varepsilon^2} = \boxed{(1 + \theta_1^2 + \theta_2^2) \sigma_\varepsilon^2 = \gamma_0}$$

Procesos $MA(2)$

Continuamos con otros valores de k :

$$E[Y_t \cdot Y_{t-k}] = E[(\varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2})(\varepsilon_{t-k} - \theta_1 \varepsilon_{t-k-1} - \theta_2 \varepsilon_{t-k-2})]$$

Entonces:

$$k = 1 \longrightarrow E[Y_t \cdot Y_{t-1}] =$$

$$= E[(\varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2})(\varepsilon_{t-1} - \theta_1 \varepsilon_{t-2} - \theta_2 \varepsilon_{t-3})] =$$

$$E[\varepsilon_t \varepsilon_{t-1} - \theta_1 \varepsilon_t \varepsilon_{t-2} - \theta_2 \varepsilon_t \varepsilon_{t-3} - \theta_1 \varepsilon_{t-1}^2 + \theta_1^2 \varepsilon_{t-1} \varepsilon_{t-2} + \theta_1 \theta_2 \varepsilon_{t-1} \varepsilon_{t-3} - \\ - \theta_2 \varepsilon_t \varepsilon_{t-2} + \theta_1 \theta_2 \varepsilon_{t-2}^2 + \theta_2^2 \varepsilon_{t-2} \varepsilon_{t-3}] =$$

$$= -\theta_1 \underbrace{E[\varepsilon_{t-1}^2]}_{\sigma_\varepsilon^2} + \theta_1 \theta_2 \underbrace{E[\varepsilon_{t-2}^2]}_{\sigma_\varepsilon^2} = \boxed{(-\theta_1 + \theta_1 \theta_2) \sigma_\varepsilon^2 = \gamma_1}$$

Procesos $MA(2)$

Continuamos con otros valores de k :

$$E[Y_t \cdot Y_{t-k}] = E[(\varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2})(\varepsilon_{t-k} - \theta_1 \varepsilon_{t-k-1} - \theta_2 \varepsilon_{t-k-2})]$$

Entonces:

$$k = 2 \longrightarrow E[Y_t \cdot Y_{t-2}] = \text{autocovarianza de orden 2}$$

$$= E[(\varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2})(\varepsilon_{t-2} - \theta_1 \varepsilon_{t-3} - \theta_2 \varepsilon_{t-4})] =$$

$$= E[\varepsilon_t \varepsilon_{t-2} - \theta_1 \varepsilon_t \varepsilon_{t-3} - \theta_2 \varepsilon_t \varepsilon_{t-4} - \theta_1 \varepsilon_{t-1} \varepsilon_{t-2} + \theta_1^2 \varepsilon_{t-1} \varepsilon_{t-3} +$$

$$+ \theta_1 \theta_2 \varepsilon_{t-1} \varepsilon_{t-4} - \theta_2 \varepsilon_{t-2}^2 + \theta_1 \theta_2 \varepsilon_{t-2} \varepsilon_{t-3} + \theta_2^2 \varepsilon_{t-2} \varepsilon_{t-4}] =$$

$$= -\theta_2 \underbrace{E[\varepsilon_{t-2}^2]}_{\sigma_\varepsilon^2} = \boxed{(-\theta_2)\sigma_\varepsilon^2 = \gamma_2}$$

Procesos $MA(2)$

Dado los procesos $MA(2)$, veamos la relación entre las funciones de autocovarianzas y autocorrelación:

$$MA(2): Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} = (1 - \theta_1 L - \theta_2 L^2) \varepsilon_t$$

Entonces:


$$\gamma_0 = (1 + \theta_1^2 + \theta_2^2) \sigma_\varepsilon^2$$

$$\gamma_1 = (-\theta_1 + \theta_1 \theta_2) \sigma_\varepsilon^2$$

$$\gamma_2 = (-\theta_2) \sigma_\varepsilon^2$$

$$\gamma_k = 0, \quad \forall k > 2$$

Así obtuvimos las distintas **autocovarianzas**.



- A partir de dichas expresiones se obtienen fácilmente los **coeficientes de autocorrelación**:

$$\rho_1 = \frac{-\theta_1 + \theta_1 \theta_2}{1 + \theta_1^2 + \theta_2^2}$$

$$\rho_2 = \frac{-\theta_2}{1 + \theta_1^2 + \theta_2^2}$$





$$\rho_k = 0 \quad \forall k > 2$$

Procesos $MA(2)$

Para que un proceso $MA(2)$ sea **invertible** se requiere que las raíces del polinomio característico: $1 - \theta_1 L - \theta_2 L^2 = 0$ caigan fuera del círculo unitario.

Esto es: $|\theta_i| < 1 \quad \forall i = 1, 2$.

Correlograma:



Comparación entre procesos $AR(p)$ y $MA(q)$

	AR	MA
Estacionariedad	Condiciones: Raíces EC < 1 Raíces PC > 1	SIEMPRE
Invertibilidad	Si es estacionario: $AR(p) \leftrightarrow MA(\infty)$	Condiciones: Raíces EC < 1 Raíces PC > 1 $MA(q) \leftrightarrow AR(\infty)$

Lecturas

Enders. Applied Econometric Time Series. Fourth Edition. Wiley Series. Leer **Capítulos 1 - 2.**

Hyndman. Forecasting: Principles and Practice. Second Edition. Monash University, Australia. Leer **Capítulo 2.**

Uriel. Análisis de Series Temporales. Modelos ARIMA. Leer **Capítulo 2** destinado a Procesos Estocástico

Peña. Análisis de Series Temporales. Alianza Editorial. Leer **Capítulos 3 - 4**

Fin

