

Análisis de Series Temporales

Clase 8 - Algoritmos Automatizados

Rodrigo Del Rosso
RDelRosso-ext@austral.edu.ar

04 de Diciembre de 2021



Agenda

- Prophet de Facebook
- Neural Prophet

Introducción

Facebook Prophet es un software de código abierto lanzado por el equipo **Core Data Science** en una publicación de Taylor y Letham del año 2017.

Es un procedimiento para pronosticar series temporales basado en un modelo aditivo que ajusta las tendencias no lineales a la estacionalidad anual, semanal y diaria, además de los efectos de eventos como vacaciones.

Funciona mejor con series que tengan fuertes efectos estacionales y varias temporadas de datos históricos.

Es robusto ante los datos faltantes y los cambios en la tendencia, y normalmente maneja bien los valores atípicos.

Está disponible para descargar en **CRAN** y **PyPI**.

Prophet

El pronóstico es una tarea de ciencia de datos que es fundamental para muchas actividades dentro de una organización.

Por ejemplo, las grandes organizaciones como Facebook deben participar en la planificación de la capacidad para asignar de manera eficiente los escasos recursos y el establecimiento de objetivos a fin de medir el desempeño en relación con una línea de base.

Producir pronósticos de alta calidad no es un problema fácil ni para las máquinas ni para la mayoría de los analistas.

Prophet

Ellos observaron dos temas principales en la práctica de crear una variedad de pronósticos comerciales:

- Las técnicas de predicción completamente automáticas pueden ser frágiles y, a menudo, demasiado inflexibles para incorporar suposiciones o heurísticas útiles.
- Los analistas que pueden producir pronósticos de alta calidad son bastante raros porque el pronóstico es una habilidad especializada en ciencia de datos que requiere una experiencia sustancial.

El resultado de estos temas es que la demanda de pronósticos de alta calidad a menudo supera con creces el ritmo al que los analistas pueden producirlos.

Prophet

Esta observación es la motivación del trabajo en la construcción de Prophet: facilitar a los expertos y no expertos la realización de pronósticos de alta calidad que se ajusten a la demanda.

Prophet está optimizado para las tareas de pronóstico empresarial que encontraron en Facebook, que normalmente tienen alguna de las siguientes características:

- observaciones por hora, diarias o semanales con al menos unos meses (preferiblemente un año) de historia
- fuertes estacionalidades múltiples de “escala humana”: día de la semana y época del año
- días festivos importantes que ocurren a intervalos irregulares que se conocen de antemano (por ejemplo, el Super Bowl)
- un número razonable de observaciones faltantes o valores atípicos grandes

Prophet

- cambios de tendencias históricas, por ejemplo, debido a lanzamientos de productos o cambios de registro
- tendencias que son curvas de crecimiento no lineales, donde una tendencia alcanza un límite natural o se satura


Encontraron la configuración predeterminada para producir pronósticos que a menudo son precisos como los producidos por pronosticadores expertos, con mucho menos esfuerzo.

Con Prophet, no está atascado con los resultados de un procedimiento completamente automático si el pronóstico no es satisfactorio: un analista sin capacitación en métodos de series de tiempo puede mejorar o ajustar los pronósticos utilizando una variedad de parámetros fácilmente interpretables.

Prophet

Han descubierto que al combinar el pronóstico automático con los pronósticos del analista en el ciclo para casos especiales, es posible cubrir una amplia variedad de casos de uso comercial.

El siguiente diagrama ilustra el proceso de pronóstico que según dichos autores funciona a escala,



Prophet

Para la fase de modelado del proceso de pronóstico, actualmente solo hay un número limitado de herramientas disponibles.

El **paquete** de Rob Hyndman en R es probablemente la opción más popular, y Google y Twitter lanzaron paquetes con funciones más específicas:

- **CausalImpact**
- **AnomalyDetection**

Existen pocos paquetes de software de código abierto para realizar pronósticos en Python.

Prophet

Con frecuencia hemos utilizado Prophet como reemplazo del paquete de pronóstico en muchos entornos debido a dos ventajas principales:

- Hace que sea mucho más sencillo crear un pronóstico razonable y preciso. El paquete de pronóstico incluye muchas técnicas de pronóstico diferentes (ARIMA, suavizado exponencial, etc.), cada una con sus propias fortalezas, debilidades y parámetros de ajuste.
- Los pronósticos se pueden personalizar de manera intuitiva para los no expertos. Hay parámetros de suavizado para la estacionalidad que le permiten ajustar la precisión con la que se ajustan a los ciclos históricos, así como parámetros de suavizado para las tendencias que le permiten ajustar la intensidad con la que se deben seguir los cambios de tendencias históricas.

Prophet

Es un modelo de regresión aditiva con cuatro componentes principales:

- Una tendencia de la curva de crecimiento logístico o lineal por partes. Prophet detecta automáticamente los cambios en las tendencias seleccionando puntos de cambio de los datos.
- Un componente estacional anual modelado utilizando series de Fourier.
- Un componente estacional semanal que utiliza variables ficticias.
- Una lista de días festivos importantes proporcionada por el usuario.

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

This specification is similar to a generalized additive model (GAM), a class of regression models with potentially non-linear smoothers applied to the regressors(...) (Taylor et al., 2017)

Prophet

Trend

Implementaron dos modelos de tendencias que cubren muchas aplicaciones de Facebook:

- a saturating growth model
- a piecewise linear model

$$g(t) = \frac{C}{1 + e^{-k(t-m)}}$$

Donde,

C : la capacidad de carga

k : la tasa de crecimiento

m : un parámetro de ajuste

Prophet

Seasonality

Se pueden aproximar los efectos estacionales suaves arbitrarios con una serie estándar de Fourier.

$$s(t) = \sum_N^{n=1} \left(a_n \cos \left(\frac{2\pi nt}{P} \right) + b_n \sin \left(\frac{2\pi nt}{P} \right) \right)$$

Esto se hace construyendo una matriz de vectores de estacionalidad para cada valor de t en los datos históricos y futuros, por ejemplo, con estacionalidad anual y $N = 10$.

$$X(t) = [\cos \left(\frac{2\pi(1)t}{365.25} \right), \dots, \sin \left(\frac{2\pi(10)t}{365.25} \right)]$$

El componente estacional se determina con la siguiente fórmula,

$$s(t) = X(t)\beta$$

En nuestro modelo generativo se toma $\beta \sim N(0, \sigma^2)$ para imponer un suavizado antes de la estacionalidad.

Prophet

Holidays and Events

La incorporación de esta lista de vacaciones en el modelo se simplifica suponiendo que los efectos de las vacaciones son independientes.

Para cada día festivo i , sea D_i el conjunto de fechas pasadas y futuras para ese día festivo.

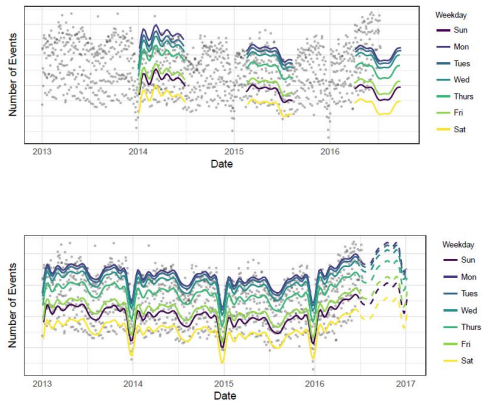
Se agrega una función indicadora que representa si el tiempo t es durante el día festivo i , y se asigna a cada día festivo un parámetro κ_i que es el cambio correspondiente en el pronóstico. Esto se hace de manera similar a la estacionalidad generando una matriz de regresores

$$Z(t) = [1(t \in D_1), \dots, 1(t \in D_L)]$$

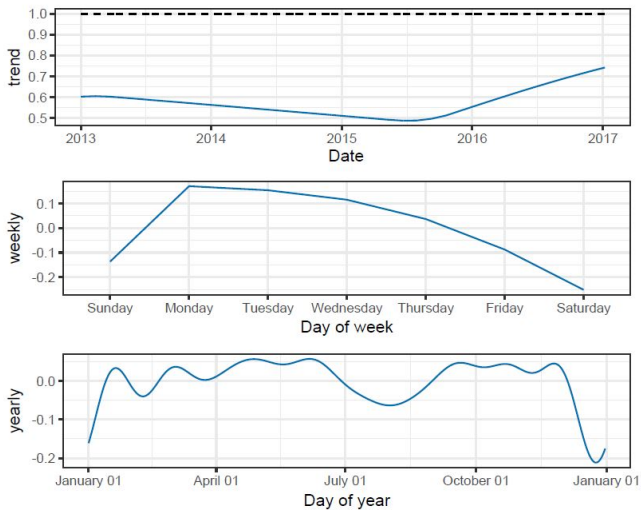
$$h(t) = Z(t)\kappa$$

Al igual que con la estacionalidad, se utiliza $\kappa \sim N(0, \nu^2)$.

Prophet



Prophet



Neural Prophet

Neural Prophet es un modelo de serie temporal basado en redes neuronales, inspirado en Facebook Prophet y **AR-Net**, construido en PyTorch.

Es una implementación de PyTorch basada en la red neuronal de una herramienta de pronóstico de series de tiempo fácil de usar para los profesionales. Esto está fuertemente inspirado en Prophet, que es la popular herramienta de pronóstico desarrollada por Facebook.

Se desarrolla en una arquitectura completamente modular que lo hace escalable para agregar cualquier componente adicional en el futuro.

Neural Prophet

Our vision is to develop a simple to use forecasting tool for users while retaining the original objectives of Prophet such as interpretability, configurability and providing much more such as the automatic differencing capabilities by using PyTorch as the backend.(...)

NeuralProphet can produce both single step and multi step-ahead forecasts. At the moment, NeuralProphet builds models univariately. This means that if you have many series that you expect to produce forecasts for, you need to do this one at a time. However, in future we hope to integrate the capability of global forecasting models into NeuralProphet.(...)

Neural Prophet

Tiene una serie de características adicionales con respecto al Prophet original:

- Gradient Descent para optimización mediante el uso de PyTorch como backend.
- Modelado de autocorrelación de series de tiempo usando AR-Net
- Modelado de regresores rezagados utilizando una red neuronal Feed-Forward separada.
- Capas profundas no lineales configurables de las FFNN.
- Ajustable a horizontes de pronóstico específicos (mayor que 1).
- Pérdidas y métricas personalizadas.

Debido a la modularidad del código y la extensibilidad admitida por PyTorch, cualquier componente que se pueda entrenar por descenso de gradiente se puede agregar como un módulo a NeuralProphet.

El uso de PyTorch como backend hace que el proceso de modelado sea mucho más rápido en comparación con el Prophet original que usa Stan como backend.

Neural Prophet

NeuralProphet ayuda a construir modelos de pronóstico para escenarios donde existen otros factores externos que pueden impulsar el comportamiento de la serie objetivo a lo largo del tiempo.

El uso de dicha información externa puede mejorar considerablemente los modelos de pronóstico en lugar de depender únicamente de la autocorrelación de la serie.

La herramienta NeuralProphet es adecuada para los profesionales de la previsión que desean obtener información sobre el proceso general de modelado mediante la visualización de las previsiones, los componentes individuales y los coeficientes subyacentes del modelo.

A través de gráficos descriptivos, los usuarios pueden visualizar la interacción de los componentes individuales. También tienen el poder de controlar estos coeficientes, según sea necesario, mediante la introducción de escasez a través de la regularización. Pueden combinar los componentes de forma aditiva o multiplicativa según su conocimiento de dominio.

Lecturas

Taylor *et al.*(2017). Forecasting at Scale.

Neural Prophet. Documentación.

Triebe *et al.*(2019). AR-Net: A simple Auto-regressive neural network for time-series.

Fin

