

# Trabajo Práctico Final

Análisis de Series Temporales

Maestría en Explotación de Datos y Gestión del Conocimiento

Layla Scheli, Franco Lianza, Lucio Scalzo, Ignacio Mujica, Alexis Walker

13 febrero 2022

# Índice

<b>1</b>	<b>Introducción</b>	<b>5</b>
<b>2</b>	<b>Marco Teórico</b>	<b>6</b>
2.1	Tests de estacionariedad . . . . .	6
2.1.1	Dickey-Fuller Aumentado . . . . .	6
2.1.2	Kwiatkowski-Phillips-Schmidt-Shin . . . . .	6
2.2	Transformaciones para estabilizar la media y la varianza . . . . .	6
2.3	Vectores autoregresivos . . . . .	7
2.4	Prophet . . . . .	7
<b>3</b>	<b>Análisis de Resultados</b>	<b>8</b>
3.1	Análisis de la series . . . . .	8
3.1.1	Índice de Precios al Consumidor . . . . .	8
3.1.2	Índice de Salarios . . . . .	9
3.1.3	Base Monetaria . . . . .	9
3.2	Vectores Autoregresivos . . . . .	10
3.2.1	Diferenciación . . . . .	11
3.2.1.1	Índice de Precios al Consumidor . . . . .	11
3.2.1.2	Índice de Salarios . . . . .	11
3.2.1.3	Base Monetaria . . . . .	12
3.2.2	Modelado . . . . .	13
3.2.3	Modelo: Índice de Precios al Consumidor y Base Monetaria . . . . .	13
3.2.3.1	Selección . . . . .	14
3.2.3.2	Análisis de diagnóstico . . . . .	14
3.2.3.3	Causalidad e Impulso Respuesta . . . . .	14
3.2.3.4	Prónósticos . . . . .	15
3.2.4	Modelo: Índice de Precios al Consumidor y Índice de Salarios . . . . .	15
3.2.4.1	Selección . . . . .	15
3.2.4.2	Análisis de diagnóstico . . . . .	16
3.2.4.3	Causalidad e Impulso Respuesta . . . . .	16
3.2.4.4	Prónósticos . . . . .	17
3.2.5	Modelo: Índice de Salarios y Base Monetaria . . . . .	17
3.2.5.1	Selección . . . . .	17
3.2.5.2	Análisis de diagnóstico . . . . .	17
3.2.5.3	Causalidad e Impulso Respuesta . . . . .	18
3.2.5.4	Prónósticos . . . . .	19

3.3	Prophet . . . . .	19
3.3.1	Índice de Precios al Consumidor . . . . .	20
3.3.2	Índice de Salarios . . . . .	21
3.3.3	Base Monetaria . . . . .	23
<b>4</b>	<b>Conclusiones</b>	<b>25</b>
<b>5</b>	<b>Referencias bibliográficas</b>	<b>26</b>
<b>6</b>	<b>Apéndices</b>	<b>27</b>
6.1	Modelo <i>VAR</i> para IPC y Base Monetaria . . . . .	27
6.2	Modelo <i>VAR</i> para IPC e Índice de Salarios . . . . .	28
6.3	Modelo <i>VAR</i> para Índice de Salarios y Base Monetaria . . . . .	29

## **Abstract**

El presente trabajo tiene por objetivo estudiar la relación entre tres variables económicas fundamentales, el Índice de precios al Consumidor (IPC), el Índice de Salarios y la Base Monetaria.

Las primeras dos son consideradas fundamentales para el desarrollo de un país ya que conllevan, en la relación entre ambas, dos efectos antagónicos según se comporten.

Por un lado, cómo evoluciona en nivel de vida de la población. Si los salarios se incrementan en mayor proporción que los bienes y servicios se mejora el bienestar ocasionando mayor demanda y, consecuentemente, el incremento de la producción.

Por otro, si los indicadores de incremento de bienes y servicios crecen a mayor ritmo que los salarios, disminuye el bienestar de la masa asalariada.

Además, como resultado del actual proceso inflacionario (elemento que sugiere incluir también en el análisis la Base Monetaria) y de la baja demanda interna hay que mencionar el perjuicio que se ocasiona a los sectores productivos internos.

Las causas que originan el fenómeno de inflación no serán tratadas por lo complejo y extenso que es el tema. Se simplifica solo evaluando la posible relación con la creación de moneda.

# 1 Introducción

Las series de tiempo son el resultado de observar valores de una variable aleatoria a lo largo del tiempo en intervalos iguales o desiguales. En el análisis de las series temporales se utilizan métodos que permiten interpretarlas y extraer información sobre las relaciones entre los datos de la serie u otras series.

Según Mochón and Beker (2008), “*La inflación es el crecimiento generalizado y continuo de los precios de los bienes y los servicios*” (p. 496), y el Índice de Precios al Consumidor (IPC) representa el costo de la canasta de bienes y servicios consumidos por la economía local.

El fenómeno de la inflación se produce por múltiples causas. Las teorías tradicionales se pueden resumir en: inflación de demanda, que se produce cuando los gastos superan la capacidad de producción de la economía, por causas monetarias, cuando se incrementa la emisión monetaria, la inflación de costos, cuando los precios suben por grupos económicos de presión y la inflación estructural, que es la que se origina debido a los problemas estructurales de las economías en vías de desarrollo.

La percepción individual sugiere que los motivos, en la coyuntura actual, son variados: especulación, emisión desmedida, presión por devaluación, bajas exportaciones, monopolios formadores de precios, elevado gasto público, mercado laboral altamente regulado, etcétera.

Analizar como evolucionan conjuntamente en el tiempo el Índice de Precios al Consumidor y el Índice de Salarios puede ayudar a clarificar los problemas y soluciones posibles.

Además, esta comparativa muestra cómo se comporta el poder adquisitivo de un empleado. Es posible determinar si se recompone conforme aumentan los precios, acompaña o se abre una brecha que da cuenta de su disminución.

Así mismo, se agrega al estudio la Base Monetaria, atendiendo a la conjetura colectiva del estrecho vínculo que existe entre emisión e inflación (sin dejar de considerar la posibles causas enumeradas anteriormente de la primera variable). Ésto con intención de reconocer si genera impacto en el Índice de Precios al Consumidor.

Índice de Precios al Consumidor, Índice de Salarios acumulados y Base Monetaria  
Con base Diciembre 2016




Fig. 1: IPC vs IS vs BM

La información fue extraída de la página oficial del Instituto Nacional de Estadística y Censos - INDEC Argentina:

- Índice de precios al consumidor
- Índice de salarios
- Base monetaria

Se considera la variación mensual acumulada estableciendo a Diciembre 2016 como el 100% y se pretende predecir los cambios de las series para Enero 2022.

## 2 Marco Teórico

Los modelos de vectores autorregresivos son validos para series de tiempo que son *estacionarias*. Se define que una serie es estacionaria de orden 2 cuando sus segundos momentos son constantes a lo largo del tiempo. Es decir, cuando su media y varianza se mantienen constantes.

Por lo contrario, una serie es *no estacionaria* cuando la tendencia y/o la variabilidad cambian a lo largo del tiempo.

El presente trabajo práctico tiene como objetivo el análisis de la estacionariedad de las series presentadas y su modelado mediante modelos VAR y Prophet.

### 2.1 Tests de estacionariedad

La estacionariedad puede ser puesta a prueba mediante diferentes tests. Se detallan los dos a utilizar.

#### 2.1.1 Dickey-Fuller Aumentado

En la ecuación de Dickey-Fuller aumentada (1):

$$\nabla Y_t = a_0 + a_1 t + (\phi_1 - 1)Y_{t-1} + \epsilon_t \quad (1)$$

Se pone a prueba el coeficiente que acompaña al rezago del período anterior:  $(\phi_1 - 1)$ .

El estadístico de este test es:

$$\tau^e = \frac{\hat{\phi}_1 - \phi_1}{\sigma(\hat{\phi}_1)} \quad (2)$$

Se plantea la regla de decisión:

Si  $\tau \leq \tau^e < 0 \Rightarrow$  No Rechazar  $H_0$

Si  $\tau^e < \tau \Rightarrow$  Rechazar  $H_0$

Como se explica en Peña Sanchez de Rivera (2010), la hipótesis nula establece que la raíz mayor de un  $AR(p+1)$  es igual a uno, por lo que el proceso es no estacionario.

#### 2.1.2 Kwiatkowski-Phillips-Schmidt-Shin

Kwiatkowski et al. (1992) definen otra prueba para raíces unitarias en la cual la hipótesis nula es contraria al test ADF, es decir, plantea que la serie temporal observable es estacionaria.

### 2.2 Transformaciones para estabilizar la media y la varianza

Según lo expresado en Peña Sanchez de Rivera (2010), la identificación de las estructuras no estacionarias consiste en detectar qué transformaciones hay que aplicar para conseguir un proceso con media y varianza constante.

En particular, consiste en determinar si es necesario: transformar la serie para que tenga varianza constante y/o diferenciarla para darle una media constante.

Por un lado, las transformaciones de potencia de Box-Cox son una forma general que permiten convertir el proceso original en un proceso condicionalmente homocedástico.

Por otro, como se puede asumir que la tendencia de una serie en el instante  $t$  es muy próxima a la del instante  $t-1$ , se puede formular una nueva serie de la manera  $Y_t = y_t - y_{t-1}$ . Este proceso se define como *diferenciación* y permite transformar una serie no estacionaria a estacionaria.

## 2.3 Vectores autoregresivos

El modelado ARIMA está limitado por su incapacidad para capturar interrelaciones dinámicas entre variables de interés. La generalización directa del modelo ARMA estacionario a la forma multivariante conduce a un modelo vectorial (George Athanasopoulos and Vahid (2012)).

Por variable en el sistema, existe una ecuación, cuyo lado derecho incluye una constante y retrasos de todas las variables presentes.

Para mantenerlo simple, se presenta un modelo VAR de dos variables con retraso igual a 1 ( $p = 1$ ):

$$y_{1,t} = c_1 + \phi_{11,1}y_{1,t-1} + \phi_{12,1}y_{2,t-1} + \epsilon_{1,t} \quad (3)$$

$$y_{2,t} = c_2 + \phi_{21,1}y_{1,t-1} + \phi_{22,1}y_{2,t-1} + \epsilon_{2,t} \quad (4)$$

Donde  $\epsilon_{1,t}$  y  $\epsilon_{2,t} \sim N(0, \sigma_y)$  y no están autocorrelacionados.  $y_{1,t}$  y  $y_{2,t}$  son estacionarias. El coeficiente  $\phi_{ii,p}$  captura la influencia del lag  $p$  de la variable  $y_i$  sobre si misma. Mientras que  $\phi_{ij,p}$  determina el peso del lag  $p$  de la variable  $y_j$  sobre  $y_i$ .

La cantidad de retardos que constituyen el modelo de mejor ajuste surge de calcular una serie de criterios de información para una secuencia de valores asignadas al parámetro.

Uno de ellos es el Error de Predicción Final (FPE de sus siglas en inglés). Según Ljung (1999), éste proporciona una medida de calidad al simular la situación en la que el modelo se prueba con un conjunto de datos diferente. Según la teoría de Akaike, el más preciso tiene el FPE más pequeño, que representa un equilibrio entre el número de parámetros y la variación explicada.

Para determinar el aporte que una variable realiza para la predicción de otra, Granger (1969) propone una prueba donde determinar si el valor actual de  $X_t$  se “predice” mejor cuando el valor actual de  $Y_t$  es incluido en el modelo.

## 2.4 Prophet

Según Taylor and Letham (2017), esta técnica propone un modelo de serie de tiempo con tres componentes principales: tendencia, estacionalidad y vacaciones. Los cuales se combinan conforme la ecuación (5).

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t \quad (5)$$

Donde  $g(t)$  es la función de tendencia que modela cambios no periódicos,  $s(t)$  representa cambios periódicos (por ejemplo, estacionalidad semanal y anual), y  $h(t)$  representa los efectos de las vacaciones. El término de error  $\epsilon_t$  representa cualquier cambio que no se adapte al modelo.

Se enmarca el problema de pronóstico como un ejercicio de ajuste de curvas, que es inherentemente diferente de los modelos de series de tiempo que explican la estructura de dependencia temporal en los datos.

Esta formulación proporciona una serie de ventajas prácticas: flexibilidad, es posible acomodar fácilmente la estacionalidad con múltiples períodos y permitir que el analista haga diferentes suposiciones sobre las tendencias; no es necesario espaciar regularmente las medidas y no es necesario interpolar los valores faltantes; el ajuste es muy rápido, lo que permite al analista explorar de forma interactiva muchas especificaciones; y, por último, el modelo de pronóstico tiene parámetros fáciles de interpretar que se pueden cambiar para imponer suposiciones.

### 3 Análisis de Resultados

#### 3.1 Análisis de la series

##### 3.1.1 Índice de Precios al Consumidor

En la Figura 2, se observa que la serie IPC es *no estacionaria* ya que su media varía a lo largo del tiempo y su función de autocorrelación decrece lentamente en forma lineal.




Fig. 2: Índice de precios al consumidor

Es posible someter la evidencia gráfica a distintas pruebas estadísticas para ratificar o rectificar lo observado.

##### Test de Estacionariedad: ADF

En la Tabla 1 se observa  $\tau^e$  entre el valor crítico y cero, lo que determina que no hay evidencia para rechazar  $H_0$  (serie no estacionaria).

	Estadístico	1pct	5pct	10pct
tau3	-2.469	-4.04	-3.45	-3.15
phi2	7.057	6.50	4.88	4.16
phi3	3.819	8.73	6.49	5.47

Tabla 1: Prueba de ADF para IPC

##### Test de Estacionariedad: KPSS

Los resultados de la prueba se encuentran detallados en la Tabla 2.

Estadístico	P-Value	Lag
1.5	0.01	3

Tabla 2: Test KPSS para IPC

En este caso el p-value es menor al grado de significación 0.05, por lo que se rechaza  $H_0$ . A diferencia de la prueba anterior, en este caso la hipótesis nula plantea estacionariedad.



En conclusión, ambos tests determinan que la serie IPC es *no estacionaria*.

### 3.1.2 Índice de Salarios

La Figura 3 muestra la serie de Índice de Salarios con evidencia gráfica de *no estacionariedad*.




Fig. 3: Índice de Salarios

#### Test de Estacionariedad: ADF

En la Tabla 3 se observa  $\tau^e$  entre el valor crítico y cero, lo que determina que no hay evidencia para rechazar  $H_0$ .

	Estadístico	1pct	5pct	10pct
tau3	-1.449	-4.04	-3.45	-3.15
phi2	7.416	6.50	4.88	4.16
phi3	2.343	8.73	6.49	5.47

Tabla 3: Prueba de ADF para Índice de Salarios

#### Test de Estacionariedad: KPSS

Los resultados de la prueba se encuentran detallados en la Tabla 4.

Estadístico	P-Value	Lag
1.5	0.01	3

Tabla 4: Test KPSS para Índice de Salarios

Ambos tests concluyen que la serie de Índice de Salarios es *no estacionaria*.

### 3.1.3 Base Monetaria

La Figura 4 muestra la serie de Base Monetaria que, al igual que las anteriores presenta comportamientos *no estacionarios*.




Fig. 4: Base Monetaria

#### Test de Estacionariedad: ADF

En la Tabla 5 se observa  $\tau^e$  entre el valor crítico y cero, lo que determina que no hay evidencia para rechazar  $H_0$ .

	Estadístico	1pct	5pct	10pct
tau3	-3.016	-4.04	-3.45	-3.15
phi2	6.808	6.50	4.88	4.16
phi3	4.886	8.73	6.49	5.47

Tabla 5: Prueba de ADF para Base Monetaria

#### Test de Estacionariedad: KPSS

Los resultados de la prueba se encuentran detallados en la Tabla 6.

Estadístico	P-Value	Lag
1.46	0.01	3

Tabla 6: Test KPSS para Base Monetaria

Ambos tests concluyen estadísticamente la *no estacionariedad* de la serie, coherente con lo que las funciones de autocorrelación hacían suponer.

## 3.2 Vectores Autoregresivos

Bajo la sospecha de la existencia de una interacción simultánea entre los grupos de variables bajo análisis, se plantea un modelo de ecuaciones donde las variables explicativas se componen del rezago de cada una de las incorporadas.

Debido a que un modelo VAR estructural se basa, entre otras cosas, en la estacionariedad de las series, la primera instancia del desarrollo es obtener transformaciones de los datos originales (ya concluida la falta de esta propiedad en la sección Análisis de la serie) para cumplir con la precondition.

### 3.2.1 Diferenciación

**3.2.1.1 Índice de Precios al Consumidor** Mediante la función `ndiffs` de R, se estima que el numero de diferenciaciones necesarias para convertir a la serie IPC en estacionaria (2 veces).

La Figura 5 muestra el Índice de Precios al Consumidor diferenciado.




Fig. 5: Índice de precio al consumidor diferenciado

#### Test de Estacionariedad: ADF

Se corrobora que la serie IPC diferenciada es estacionaria mediante el test Dickey-Fuller aumentado (Tabla 7). El valor de  $\tau^e$  se encuentra dentro de la zona de rechazo, por lo que se concluye la no aceptación de  $H_0$ .

	Estadístico	1pct	5pct	10pct
tau3	-7.139	-4.04	-3.45	-3.15
phi2	16.994	6.50	4.88	4.16
phi3	25.486	8.73	6.49	5.47

Tabla 7: Test de ADF para IPC diferenciada

#### Test de Estacionariedad: KPSS

El test KPSS coincide con ADF. El p-value es mayor al grado de significación de 0.05, por lo que no se rechaza la hipótesis nula de estacionariedad.

Estadístico	P-Value	Lag
0.055	0.1	3

Tabla 8: Test KPSS para IPC diferenciada

Se confirma entonces que la serie diferenciada es *estacionaria*.

**3.2.1.2 Índice de Salarios** En la Figura 3 se observa que, al igual que la serie IPC, el Índice de Salarios tampoco es estacionario.

Mediante la función `ndiffs` de R, se estima que el número de diferenciaciones necesarias para convertir la serie en estacionaria. El resultado obtenido es 1.




Fig. 6: Índice de Salarios diferenciado

#### Test de Estacionariedad: ADF

Al aplicar el test ADF a la serie diferenciada, el valor de  $\tau^e$  se encuentra en la zona de rechazo de  $H_0$ , por lo que se confirma que la serie diferenciada es estacionaria.

	Estadístico	1pct	5pct	10pct
tau3	-4.341	-4.04	-3.45	-3.15
phi2	6.361	6.50	4.88	4.16
phi3	9.435	8.73	6.49	5.47

Tabla 9: Prueba de ADF para Índice de Salarios diferenciado

#### Test de Estacionariedad: KPSS

El test KPSS concuerda con el test ADF, concluyendo que la serie diferenciada es *estacionaria*.

Estadístico	P-Value	Lag
0.367	0.091	3

Tabla 10: Test KPSS para Índice de Salarios diferenciado

**3.2.1.3 Base Monetaria** Mediante la función `ndiffs` de R, se estima que el numero de diferenciaciones necesarias para convertir a la serie Base Monetaria en estacionaria es 1.

La Figura 7 muestran los valores diferenciado.




Fig. 7: Base Monetaria diferenciada

#### Test de Estacionariedad: ADF

Se corrobora que la serie diferenciada es estacionaria mediante el test Dickey-Fuller aumentado (Tabla 11). El valor de  $\tau^e$  se encuentra dentro de la zona de rechazo de la hipótesis nula.

	Estadístico	1pct	5pct	10pct
tau3	-6.761	-4.04	-3.45	-3.15
phi2	15.245	6.50	4.88	4.16
phi3	22.857	8.73	6.49	5.47

Tabla 11: Test de ADF para Base Monetaria diferenciada

#### Test de Estacionariedad: KPSS

El test KPSS coincide con ADF. El p-value es mayor al grado de significación de 0.05, por lo que no se rechaza la hipótesis nula.

Estadístico	P-Value	Lag
0.125	0.1	3

Tabla 12: Test KPSS para Base Monetaria diferenciada

Se confirma entonces que la serie diferenciada es *estacionaria*.

### 3.2.2 Modelado

Con el objeto principal de analizar causalidad entre series se proponen modelos agrupando de a pares los datos que se utilizan.

Se calculan y muestran distintos criterios de selección para determinar el modelo que mejor ajusta, sin embargo se trabaja con el *Error de Predicción Final* (FPE) para determinar que retardo utilizar.

### 3.2.3 Modelo: Índice de Precios al Consumidor y Base Monetaria

AIC(n)	HQ(n)	SC(n)	FPE(n)
1	1	1	1

Tabla 13: Criterios de selección

**3.2.3.1 Selección** En la tabla 13, se sugieren que el uso de retardo igual a 1 es apropiado para estimar el modelo. El resumen del mismo se incluye en el Apendice.

**3.2.3.2 Análisis de diagnóstico** Para evaluar el ajuste del modelo se ejecutan algunas pruebas de diagnostico sobre los residuos del modelo.

Estadístico	Parámetro	P Value
53.974	44	0.144

Tabla 14: Test de Portmanteau para la correlación de residuos

Con la prueba de Portmanteau se revisa correlación. Según la Tabla 14, un p-value mayor al 5% indica la ausencia de correlación, no se rechaza la hipótesis nula de correlación.

Es posible tener evidencia de homocedasticidad utilizando la prueba Multiplicador de Lagrange, para efectos ARCH.

Estadístico	Parámetro	P Value
111.486	108	0.39

Tabla 15: Test ARCH para la homocedasticidad de los residuos

En la Tabla 15 se observa un p-value por encima del valor crítico lo que no brinda evidencia suficiente para rechazar la hipótesis nula de homocedasticidad.

Se utiliza la prueba de Jarque-Bera para comprobar si una muestra de datos tiene la asimetría y la curtosis de una distribución normal.

	Estadístico	Parámetro	P Value
Jarque-Bera	33.536	4	0
Asimetría	15.898	2	0
Curtosis	17.639	2	0

Tabla 16: Normalidad de los residuos

Los resultados resumidos en la Tabla 16 no muestran residuos distribuidos normalmente. Si se analizan los generados por cada ecuación por separado, la prueba de Shapiro-Wilk (p-value igual a 0.7978383) para el índice de precios señala normalidad, mientras que para la base monetaria no (p-value igual a  $4.2302951 \times 10^{-4}$ ).

De revisar la Figura 1 se observa un valor atípico para el mes de marzo de 2020, eliminando esta lectura se obtiene un p-value igual a 0.1094823 observando normalidad.

**3.2.3.3 Causalidad e Impulso Respuesta** En este punto es posible probar la causalidad de Granger.

Método	P-Value
Granger causality H0: train_bm do not Granger-cause train_ipc	0.726
Granger causality H0: train_ipc do not Granger-cause train_bm	0.022

Tabla 17: Causalidad de Grange: Base Monetaria e IPC

En la Tabla 17 se observa evidencia que el Índice de Precios al Consumidor es causa de la Base Monetaria.

Se genera la función Impulso-Respuesta para describir la respuesta de la Base Monetaria a un *shock* de IPC.

Impulso Respuesta: IPC y Base Monetaria




Fig. 8: Impulso Respuesta: IPC y Base Monetaria

En la Figura 8 se identifica que los *shocks* en IPC no tienen un impacto de largo plazo en la Base Monetaria, su efecto desaparece después de 4 meses. Contribuyen a la variabilidad a corto plazo.

**3.2.3.4 Pronósticos** En la figura 9 se presenta el resultado gráfico de estimar las variables incluidas.

Series con sus pronósticos




Fig. 9: Predicciones

### 3.2.4 Modelo: Índice de Precios al Consumidor y Índice de Salarios

AIC(n)	HQ(n)	SC(n)	FPE(n)
8	4	1	4

Tabla 18: Criterios de selección

**3.2.4.1 Selección** En la tabla 18, se sugieren que el uso de retardo igual a 4 es apropiado para estimar el modelo. El resumen se incluye en el Apéndice.

**3.2.4.2 Análisis de diagnóstico** Para evaluar el ajuste del modelo se ejecutan algunas pruebas de diagnostico sobre los residuos del modelo.

Estadístico	Parámetro	P Value
35.97	32	0.288

Tabla 19: Test de Portmanteau para la correlación de residuos

Con la prueba de Portmanteau se revisa correlación. Según la Tabla 19, un p-value mayor al 5% indica la ausencia de correlación, no se rechaza la hipótesis nula de correlación.

Es posible tener evidencia de homocedasticidad utilizando la prueba Multiplicador de Lagrange, para efectos ARCH.

Estadístico	Parámetro	P Value
105	108	0.564

Tabla 20: Test ARCH para la homocedasticidad de los residuos

En la Tabla 20 se observa un p-value por encima del valor crítico lo que no brinda evidencia suficiente para rechazar la hipótesis nula de homocedasticidad.

Se utiliza la prueba de Jarque-Bera para comprobar si una muestra de datos tiene la asimetría y la curtosis de una distribución normal.

	Estadístico	Parámetro	P Value
Jarque-Bera	3.920	4	0.417
Asimetría	2.776	2	0.250
Curtosis	1.144	2	0.564

Tabla 21: Normalidad de los residuos

Todos los estadísticos brindan información para reconocer normalidad en la distribución de los errores.

**3.2.4.3 Causalidad e Impulso Respuesta** En este punto es posible probar la causalidad de Granger.

Método	P-Value
Granger causality H0: train_is do not Granger-cause train_ipc	<b>0.007</b>
Granger causality H0: train_ipc do not Granger-cause train_is	0.120

Tabla 22: Causalidad de Grange: Índice de Salarios e IPC

En la Tabla 22 se observa evidencia que el Índice de Salarios es causa del de Precios al Consumidor.

Se genera la función Impulso-Respuesta para describir la respuesta de IPC a un *shock* en los salarios.






Fig. 10: Impulso Respuesta: IPC y Índice de Salarios

Gráficamente (Figura 10), los *shocks* en el Índice de Salarios tienen un impacto a largo plazo en IPC, sus efectos se atenuan pasado el año.

**3.2.4.4 Pronósticos** En la figura 11 se presenta el resultado gráfico de estimar las variables incluidas.

Series con sus pronosticos




Fig. 11: Predicciones

### 3.2.5 Modelo: Índice de Salarios y Base Monetaria

AIC(n)	HQ(n)	SC(n)	FPE(n)
11	1	1	6

Tabla 23: Criterios de selección

**3.2.5.1 Selección** En la tabla 23, se sugieren que el uso de retardo igual a 6 es apropiado para estimar el modelo. El resumen se incluye en el Apéndice.

**3.2.5.2 Análisis de diagnóstico** Para evaluar el ajuste del modelo se ejecutan algunas pruebas de diagnóstico sobre los residuos del modelo.

Estadístico	Parámetro	P Value
32.747	24	0.11

Tabla 24: Test de Portmanteau para la correlación de residuos

Con la prueba de Portmanteau se revisa correlación. Según la Tabla 24, un p-value mayor al 5% indica la ausencia de correlación, no se rechaza la hipótesis nula de correlación.

Es posible tener evidencia de homocedasticidad utilizando la prueba Multiplicador de Lagrange, para efectos ARCH.

Estadístico	Parámetro	P Value
99	108	0.721

Tabla 25: Test ARCH para la homocedasticidad de los residuos

En la Tabla 25 se observa un p-value por encima del valor crítico lo que no brinda evidencia suficiente para rechazar la hipótesis nula de homocedasticidad.

Se utiliza la prueba de Jarque-Bera para comprobar si una muestra de datos tiene la asimetría y la curtosis de una distribución normal.

	Estadístico	Parámetro	P Value
Jarque-Bera	8.616	4	0.071
Asimetría	5.898	2	0.052
Curtosis	2.718	2	0.257

Tabla 26: Normalidad de los residuos

Todos los estadísticos brindan información para reconocer normalidad en la distribución de los errores.

**3.2.5.3 Causalidad e Impulso Respuesta** En este punto es posible probar la causalidad de Granger.

Método	P-Value
Granger causality H0: train_bm do not Granger-cause train_is	0.059
Granger causality H0: train_is do not Granger-cause train_bm	<b>0.013</b>

Tabla 27: Causalidad de Grange: Base Monetaria e Índice de Salarios

En la Tabla 27 se observa evidencia que el Índice de Salarios es causa de la Base Monetaria.

Se genera la función Impulso-Respuesta para describir la respuesta de la Base Monetaria a un *shock* en los salarios.




Fig. 12: Impulso Respuesta: Base Monetaria e Índice de Salarios

Gráficamente (Figura 12), los *shocks* en el Índice de Salarios tienen un impacto a mediano plazo en la Base Monetaria, sus efectos perduran aproximadamente 10 meses después de su ocurrencia.

**3.2.5.4 Pronósticos** En la figura 13 se presenta el resultado gráfico de estimar las variables incluidas.




Fig. 13: Predicciones

### 3.3 Prophet

Otra forma de modelar las series analizadas anteriormente es mediante Prophet. Se trabaja con cada una de forma independiente, separando el conjunto de datos en train y test. Donde se considera train hasta el 2021-04-01 y test hasta el 2021-07-01.

Una de las ventajas que posee Prophet es que puede tener en cuenta eventos como las vacaciones nacionales en el análisis de la serie. Debido a que gran parte de la economía argentina responde a situaciones políticas del momento, resulta interesante tener en cuenta los siguientes eventos:

- Elecciones PASO (2019-08-11)
- Elecciones Presidenciales (2019-10-27)
- Anuncio del aislamiento preventivo y obligatorio por COVID (2020-03-20)

Se utiliza esta técnica para modelar las 3 series, teniendo en cuenta dichos eventos.

### 3.3.1 Índice de Precios al Consumidor

Se entrena un modelo Prophet para Índice de Precios al Consumidor y se analizan las métricas de performance. En la Tabla 28 se detallan las métricas de testing obtenidas.

Modelo	ME	RMSE	MAE	MPE	MAPE
Prophet	2.757	2.886	2.757	1.056	1.056
VAR IPC-BM	2.250	2.473	2.250	0.852	0.852
VAR IPC-IS	0.193	0.219	0.193	0.074	0.074

Tabla 28: Métricas de los modelos de Indice de Precios al Consumidor




Fig. 14: Predicciones de IPC

Ambos modelos *VAR* que ajustan IPC obtuvieron mejores métricas en test a comparación del modelo *Prophet*. Sin embargo, los intervalos de confianza de las predicciones son mas acotados en el modelo *Prophet* que los obtenidos con los modelos *VAR*.

La Figura 15 muestra la descomposición de los componentes del modelo.




Fig. 15: Componentes del modelo Prophet

Analizando las componentes, se concluye que:

- El Índice de Precios al Consumidor acumulado presenta una tendencia positiva, de forma cuasi lineal.
- Ambas elecciones afectaron la serie de forma positiva, aumentando entre 1,5pp y 3pp por sobre la tendencia. Del otro lado, el inicio del aislamiento por COVID afecta la serie disminuyendo un 1pp.
- Entre fin de agosto e inicios de septiembre la serie presenta una estacionalidad positiva, lo que provoca un aumento mayor que los meses anteriores. A finales de octubre este comportamiento se revierte.

### 3.3.2 Índice de Salarios

Se entrena un modelo Prophet para Índice de Salarios y se analizan las métricas de performance. En la Tabla 29 se detallan las métricas de testing obtenidas.

Modelo	ME	RMSE	MAE	MPE	MAPE
Prophet	5.495	5.675	5.495	2.317	2.317
VAR IPC-IS	-2.337	2.508	2.337	-0.995	0.995
VAR IS-BM	-2.676	2.938	2.676	-1.141	1.141

Tabla 29: Métricas de los modelos de Índice de Salarios




Fig. 16: Predicciones de Indice Salarios

Ambos modelos *VAR* que modelan el Índice de Salarios obtuvieron mejores métricas en test a comparación del modelo *Prophet*. Sin embargo, los intervalos de confianza de las predicciones son mas acotados en el modelo *Prophet* que los obtenidos con los modelos *VAR*.

La Figura 17 muestra la descomposición de los componentes del modelo.




Fig. 17: Componentes del modelo Prophet

Analizando las componentes, se concluye que:

- El Índice de Salarios acumulado presenta una tendencia positiva, de forma cuasi lineal.
- Ambas elecciones afectaron la serie de forma positiva, aumentando aproximadamente en un 2pp por sobre la tendencia. El inicio del aislamiento por COVID afecta la serie aumentándola un 3,5pp.
- La serie presenta una estacionalidad positiva en diciembre, aumentando el valor de la misma para mediados de mes.

### 3.3.3 Base Monetaria

Se entrena un modelo Prophet para la Base Monetaria acumulada y se analizan las métricas de performance. En la Tabla 30 se detallan las métricas de testing obtenidas.

Modelo	ME	RMSE	MAE	MPE	MAPE
Prophet	-3.651	4.263	3.651	-1.551	1.551
VAR IPC-BM	-5.846	6.690	5.846	-2.532	2.532
VAR IS-BM	-5.830	6.557	5.830	-2.542	2.542

Tabla 30: Métricas de los modelos de Base Monetaria

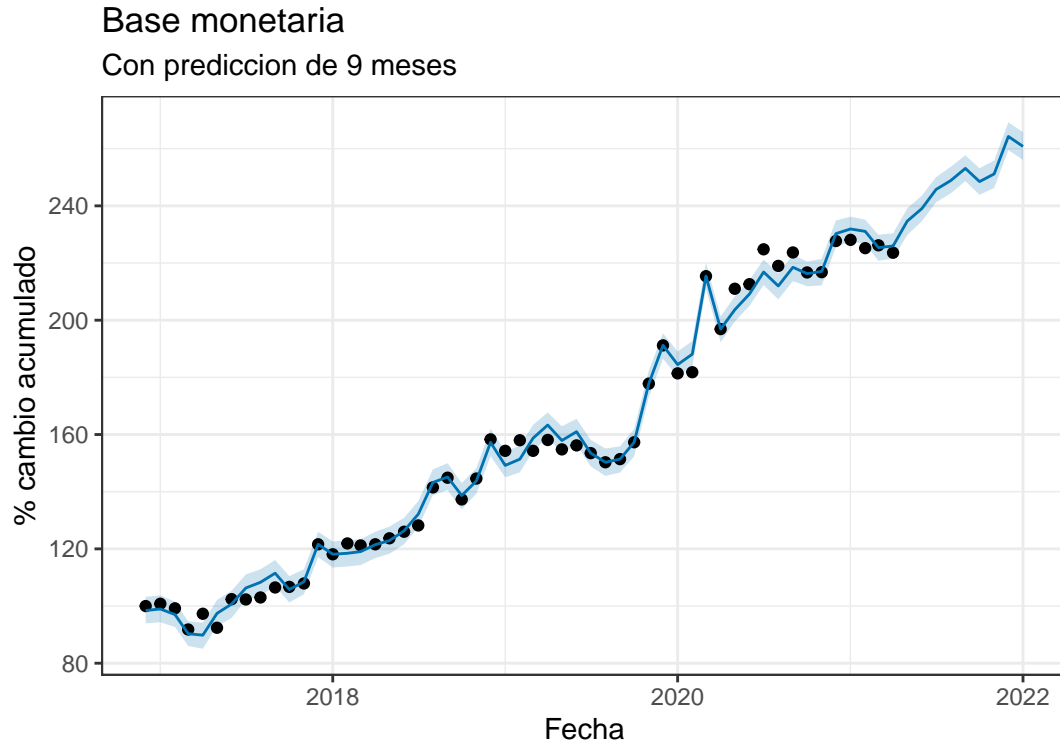


Fig. 18: Predicciones de Base Monetaria

El modelo *Prophet* es el que mejor ajusta a la serie de Base Monetaria, superando a los modelos *VAR*. A su vez, los intervalos de confianza de sus predicciones son mas acotadas que las de los modelos *VAR*.

La Figura 19 muestra la descomposición de los componentes del modelo.




Fig. 19: Componentes del modelo Prophet

Analizando las componentes, se concluye que:

- La Base Monetaria acumulada presenta una tendencia positiva, de forma cuasi lineal.
- Ambas elecciones afectaron la serie de forma negativa, disminuyendo aproximadamente en un 25pp la Base Monetaria acumulada por sobre la tendencia. El inicio del aislamiento por COVID afecta la serie aumentándola hasta un 20pp sobre la tendencia.
- A mitad de año la Base Monetaria presenta su pico máximo de estacionalidad positiva, coincidiendo con los aguinaldos.



## 4 Conclusiones

Queda en evidencia que la tendencia del Índice de Precios al Consumidor y el Índice de Salarios profundizan una brecha que son altamente negativas para la economía local.

De no realizarse cambios en el rumbo económico que impliquen mejoras en: el aspecto financiero (bajar el ritmo de emisión monetaria), incrementar las exportaciones para solventar la balanza de pagos y tipo de cambio, fomentar la producción nacional, para utilizar al máximo la capacidad instalada y poder disminuir las importaciones y luego con el crecimiento disminuir los impuestos para ser más competitivos, no se logran mejorar los indicadores y el salario real seguirá decreciendo.

Respecto a la causalidad o impacto que estos indicadores tienen entre sí, hay falta de evidencia en los modelos simplificados que la tendencia de la Base Monetaria afecte el Índice de Precios al Consumidor; la conjetura del directo impacto de la emisión en la inflación no se hace visible entre los índices utilizados. Parece que encontrar esta dependencia implica complejizar el análisis sumando información al estudio.




Fig. 20: Causalidad

Desde un punto de vista técnico, las series que tienen una variación relativamente constante en signo y valor (IPC e Índice de Salarios), son mejor explicadas con la incorporación de las lecturas de otras. Mientras la que muestra rango mensuales más amplios y en distintas direcciones (Base Monetaria), la segunda técnica aplicada ajusta mejor; algo visible no solo en los criterios de información sino también en los amplios intervalos de confianza producto de su variabilidad.

## 5 Referencias bibliográficas

- George Athanasopoulos, D. S. Poskitt, and Farshid Vahid. 2012. “Two Canonical VARMA Forms: Scalar Component Models Vis-à-Vis the Echelon Form.” *Econometric Reviews* 31 (1): 60–83.
- Granger, C. W. J. 1969. “Investigating Causal Relations by Econometric Models and Cross-Spectral Methods.” *Econometrica* 37 (3): 424–38.
- Kwiatkowski, Denis, Peter C. B. Phillips, Peter Schmidt, and Yongcheol Shin. 1992. “Testing the Null Hypothesis of Stationarity Against the Alternative of a Unit Root: How Sure Are We That Economic Time Series Have a Unit Root?” *Journal of Econometrics* 54 (1): 159–78.
- Ljung, L. 1999. *System Identification: Theory for the User*. Prentice-Hall PTR.
- Mochón, F., and V. Beker. 2008. *Economía, Principios y Aplicaciones*. McGraw Hill.
- Peña Sanchez de Rivera, D. 2010. *Análisis de Series Temporales*. Alianza Editorial S.A.
- Taylor, S. J., and B. Letham. 2017. “Forecasting at Scale.”

## 6 Apéndices

### 6.1 Modelo *VAR* para IPC y Base Monetaria

```
##
## VAR Estimation Results:
## =====
## Endogenous variables: train_ipc, train_bm
## Deterministic variables: const
## Sample size: 50
## Log Likelihood: -243.105
## Roots of the characteristic polynomial:
## 0.3654 0.1086
## Call:
## VAR(y = ipc_bm, p = lags, type = "const", exogen = NULL)
##
##
## Estimation results for equation train_ipc:
## =====
## train_ipc = train_ipc.l1 + train_bm.l1 + const
##
##               Estimate Std. Error t value Pr(>|t|)
## train_ipc.l1 -0.218251   0.146709  -1.488   0.144
## train_bm.l1  -0.006506   0.018483  -0.352   0.726
## const         0.070285   0.156574   0.449   0.656
##
##
## Residual standard error: 1.06 on 47 degrees of freedom
## Multiple R-Squared: 0.05547, Adjusted R-squared: 0.01527
## F-statistic: 1.38 on 2 and 47 DF, p-value: 0.2616
##
##
## Estimation results for equation train_bm:
## =====
## train_bm = train_ipc.l1 + train_bm.l1 + const
##
##               Estimate Std. Error t value Pr(>|t|)
## train_ipc.l1  -2.4792     1.0685  -2.320 0.02472 *
## train_bm.l1   -0.2558     0.1346  -1.900 0.06356 .
## const         3.2882     1.1404   2.883 0.00592 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
## Residual standard error: 7.724 on 47 degrees of freedom
## Multiple R-Squared: 0.2016, Adjusted R-squared: 0.1677
## F-statistic: 5.936 on 2 and 47 DF, p-value: 0.00503
##
##
## Covariance matrix of residuals:
##      train_ipc train_bm
## train_ipc    1.125    1.494
## train_bm     1.494   59.656
##
## Correlation matrix of residuals:
##      train_ipc train_bm
## train_ipc    1.0000    0.1824
```

```
## train_bm      0.1824    1.0000
```

## 6.2 Modelo VAR para IPC e Índice de Salários

```
##
## VAR Estimation Results:
## =====
## Endogenous variables: train_ipc, train_is
## Deterministic variables: const
## Sample size: 47
## Log Likelihood: -123.89
## Roots of the characteristic polynomial:
## 0.8408 0.8408 0.8363 0.8363 0.7899 0.6336 0.6336 0.3134
## Call:
## VAR(y = ipc_is, p = lags, type = "const", exogen = NULL)
##
##
## Estimation results for equation train_ipc:
## =====
## train_ipc = train_ipc.l1 + train_is.l1 + train_ipc.l2 + train_is.l2 + train_ipc.l3 + train_is.l3 + train_ip
##
##           Estimate Std. Error t value Pr(>|t|)
## train_ipc.l1 -0.2889      0.1500  -1.926  0.06158 .
## train_is.l1  -0.1083      0.1234  -0.878  0.38540
## train_ipc.l2 -0.3656      0.1407  -2.599  0.01325 *
## train_is.l2   0.2368      0.1388   1.706  0.09617 .
## train_ipc.l3 -0.1447      0.1429  -1.013  0.31735
## train_is.l3  -0.5020      0.1412  -3.555  0.00103 **
## train_ipc.l4 -0.2322      0.1371  -1.694  0.09844 .
## train_is.l4   0.0277      0.1430   0.194  0.84744
## const         0.9459      0.4652   2.033  0.04904 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
## Residual standard error: 0.9144 on 38 degrees of freedom
## Multiple R-Squared: 0.4118, Adjusted R-squared: 0.2879
## F-statistic: 3.325 on 8 and 38 DF, p-value: 0.005602
##
##
## Estimation results for equation train_is:
## =====
## train_is = train_ipc.l1 + train_is.l1 + train_ipc.l2 + train_is.l2 + train_ipc.l3 + train_is.l3 + train_ip
##
##           Estimate Std. Error t value Pr(>|t|)
## train_ipc.l1  0.14425      0.18135   0.795 0.431325
## train_is.l1   0.56608      0.14913   3.796 0.000515 ***
## train_ipc.l2  0.06181      0.17009   0.363 0.718336
## train_is.l2  -0.05335      0.16779  -0.318 0.752244
## train_ipc.l3 -0.06372      0.17270  -0.369 0.714227
## train_is.l3  -0.14027      0.17071  -0.822 0.416368
## train_ipc.l4  0.38545      0.16574   2.326 0.025472 *
## train_is.l4   0.16565      0.17290   0.958 0.344094
## const         1.17649      0.56243   2.092 0.043192 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
```

```
## Residual standard error: 1.106 on 38 degrees of freedom
## Multiple R-Squared: 0.3574, Adjusted R-squared: 0.2221
## F-statistic: 2.642 on 8 and 38 DF, p-value: 0.02081
##
##
##
## Covariance matrix of residuals:
##          train_ipc train_is
## train_ipc  0.83616  0.02197
## train_is   0.02197  1.22223
##
## Correlation matrix of residuals:
##          train_ipc train_is
## train_ipc  1.00000  0.02173
## train_is   0.02173  1.00000
```

### 6.3 Modelo *VAR* para Índice de Salarios y Base Monetaria

```
##
## VAR Estimation Results:
## =====
## Endogenous variables: train_is, train_bm
## Deterministic variables: const
## Sample size: 45
## Log Likelihood: -204.075
## Roots of the characteristic polynomial:
## 0.9124 0.9124 0.8811 0.8811 0.8639 0.8639 0.8421 0.8421 0.8338 0.8338 0.8061 0.5817
## Call:
## VAR(y = is_bm, p = lags, type = "const", exogen = NULL)
##
##
## Estimation results for equation train_is:
## =====
## train_is = train_is.l1 + train_bm.l1 + train_is.l2 + train_bm.l2 + train_is.l3 + train_bm.l3 + train_is.l4
##
##          Estimate Std. Error t value Pr(>|t|)
## train_is.l1  0.46555    0.16452   2.830  0.00798 **
## train_bm.l1  0.03253    0.02476   1.314  0.19823
## train_is.l2  0.07371    0.17619   0.418  0.67850
## train_bm.l2  0.01846    0.02619   0.705  0.48601
## train_is.l3 -0.09341    0.18206  -0.513  0.61141
## train_bm.l3  0.02568    0.02326   1.104  0.27777
## train_is.l4  0.15121    0.19416   0.779  0.44182
## train_bm.l4 -0.02571    0.02360  -1.089  0.28415
## train_is.l5 -0.35094    0.20175  -1.739  0.09156 .
## train_bm.l5 -0.06612    0.02269  -2.914  0.00646 **
## train_is.l6  0.14929    0.17770   0.840  0.40707
## train_bm.l6 -0.04777    0.02242  -2.130  0.04094 *
## const        1.67630    0.65192   2.571  0.01498 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
## Residual standard error: 1.062 on 32 degrees of freedom
## Multiple R-Squared: 0.4817, Adjusted R-squared: 0.2873
## F-statistic: 2.478 on 12 and 32 DF, p-value: 0.02014
##
##
```

```

## Estimation results for equation train_bm:
## =====
## train_bm = train_is.l1 + train_bm.l1 + train_is.l2 + train_bm.l2 + train_is.l3 + train_bm.l3 + train_is.l4
##
##           Estimate Std. Error t value Pr(>|t|)
## train_is.l1 -2.018367   1.143235  -1.765   0.0870 .
## train_bm.l1 -0.286519   0.172024  -1.666   0.1056
## train_is.l2  3.220059   1.224328   2.630   0.0130 *
## train_bm.l2 -0.026144   0.181997  -0.144   0.8867
## train_is.l3 -3.127659   1.265081  -2.472   0.0189 *
## train_bm.l3 -0.067339   0.161599  -0.417   0.6797
## train_is.l4  1.988008   1.349163   1.474   0.1504
## train_bm.l4  0.291618   0.163997   1.778   0.0849 .
## train_is.l5  2.212640   1.401928   1.578   0.1243
## train_bm.l5  0.009655   0.157685   0.061   0.9516
## train_is.l6 -2.464430   1.234782  -1.996   0.0545 .
## train_bm.l6  0.041577   0.155822   0.267   0.7913
## const       3.162788   4.530090   0.698   0.4901
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
## Residual standard error: 7.378 on 32 degrees of freedom
## Multiple R-Squared:  0.4698, Adjusted R-squared:  0.271
## F-statistic: 2.363 on 12 and 32 DF, p-value: 0.02598
##
##
## Covariance matrix of residuals:
##           train_is train_bm
## train_is    1.127   -1.565
## train_bm   -1.565   54.433
##
## Correlation matrix of residuals:
##           train_is train_bm
## train_is    1.0000  -0.1997
## train_bm   -0.1997   1.0000

```